

SolUno

Agente de IA orquestado por n8n · Sistema operativo de incidencias para BancoSol

01 · SECCIÓN

La promesa técnica

SolUno es un **agente de IA desplegado on-premise** dentro de BancoSol, **orquestado visualmente por n8n**, que ingiere reportes desde los nueve canales de atención existentes (WhatsApp, FonoSol, appSol, Solnet, altoke, sucursal, chatbot, redes sociales y Punto de Reclamo web), los **tokeniza on-premise** antes de cualquier salida al exterior, los **clusteriza por incidente subyacente** mediante embeddings vectoriales en pgvector, **responde al cliente en su idioma nativo** — incluyendo guaraní, quechua y aymara — y **escala al humano correcto del banco** solo cuando una decisión crítica o una acción en el mundo físico lo requiere.

El agente IA es el cerebro. n8n es el sistema nervioso. El humano es el músculo y la conciencia ética. Ningún byte de PII cruza el perímetro de BancoSol; el LLM en cloud solo ve patrones anónimos bajo contrato Zero Data Retention. El resultado: **200 reclamos en 9 canales convertidos en 1 incidente con 200 afectados, detectado en 14 minutos, respondido al cliente en su idioma, sin un solo dato confidencial fuera del banco.**

FRASE EJECUTIVA

El agente IA decide lo rutinario y propone lo importante. n8n conecta cada decisión con cada herramienta. El humano aprueba lo crítico y ejecuta lo físico. El cliente solo siente el resultado.

02 · SECCIÓN

Quién hace qué — los tres actores del sistema

SolUno tiene tres protagonistas trabajando juntos. Cada uno con un rol claro, ninguno funciona sin los otros.

AGENTE IA

El cerebro. Razona, clasifica, agrupa, decide qué responder al cliente con plantillas aprobadas, detecta patrones de fraude. Trabaja autónomamente en lo rutinario y propone borradores en lo importante.

n8n

El sistema nervioso. Motor de automatización visual open source instalado dentro de BancoSol. Recibe mensajes, enruta al agente, conecta al agente con sus herramientas (core bancario, base de conocimiento, WhatsApp, base de datos), ejecuta cada paso en orden y deja todo auditable.

**HUMANO DEL
BANCO**

El músculo y la conciencia ética. Hace lo que requiere manos en el mundo físico (arreglar el cajero, desplegar el fix, bloquear tarjetas, hablar con autoridades) y aprueba lo crítico (cerrar reclamos, marcar fraude confirmado, escalar casos sensibles). Nunca queda fuera del loop en decisiones importantes.

Lo que el cliente vive (lo que no cambia para él)

Doña Justina, vendedora del Abasto en Santa Cruz, abre su WhatsApp como siempre y manda un audio en guaraní al número de BancoSol (62302300, el que ya existe hoy): «*Mi tarjeta no funciona en el cajero de la Ramada, hace 20 minutos que estoy esperando*».

En **menos de un minuto** recibe una respuesta automática por el mismo WhatsApp, en guaraní: «*Tu reporte está vinculado al incidente INC-1184 junto con otros 6 afectados. ETA de resolución: 14:30. Te avisamos por este mismo canal. ASFI #24007*».

Cuando el cajero se arregla, recibe un segundo mensaje: «*El cajero ya funciona. Gracias por reportar*». Fin.

CERO FRICCIÓN PARA EL CLIENTE

Para Doña Justina no hubo app nueva que descargar, formulario que llenar, número de cuenta que escribir ni cola que esperar. Habló en su idioma, por el canal de siempre.

Lo que pasa por dentro — flujo completo paso a paso

01

n8n recibe el mensaje (ingesta)

Un workflow en n8n tiene un trigger conectado a la API de WhatsApp Cloud. Cuando llega el audio de Doña Justina, n8n lo captura, le agrega metadata (canal, timestamp, geolocalización, número remitente) y dispara el workflow de procesamiento. Lo mismo ocurre para cualquiera de los nueve canales — n8n tiene un nodo trigger para cada uno.

02

Tokenización on-premise (privacidad por diseño)

Antes de que el mensaje toque cualquier servicio externo, n8n invoca un módulo local de tokenización que vive dentro del banco. Reemplaza toda PII por tokens genéricos: «*Soy Juana Mamani, CI 8472351, cuenta 4001-2289-44*» se convierte en «*Soy {NAME_001}, CI {ID_001}, cuenta {ACCT_001}*». La tabla token-a-dato vive en un vault dentro del banco y nunca se exporta.

03

Identificación del cliente por contexto

n8n consulta el CRM de BancoSol para identificar al cliente por el número de teléfono del WhatsApp. El cliente nunca tuvo que escribir su número de cuenta, su CI ni ninguna clave. Esto es UX para el cliente rural y al mismo tiempo seguridad contra phishing.

04

Transcripción multilingüe on-premise

Como el mensaje es un audio en guaraní, n8n lo pasa a Whisper corriendo en GPU local del banco. El audio nunca sale del perímetro de BancoSol. Misma lógica para español, quechua y aymara.

05

Invocación del agente IA

n8n llama al nodo del agente IA pasándole el texto ya tokenizado y la metadata. El agente tiene nueve herramientas conectadas, todas accesibles a través de n8n: buscar en base de conocimiento, consultar core bancario, buscar incidentes similares, generar número ASFI, redactar respuesta, agendar seguimiento, escalar a humano, alertar al SOC, enviar mensaje al cliente.

06

Clasificación según ASFI

El agente envía el texto tokenizado al LLM cloud (Claude bajo Zero Data Retention) que devuelve la clasificación según las categorías ASFI: tarjeta débito, crédito, internet banking, atención al cliente, cuentas de ahorro. También evalúa severidad y urgencia. El LLM solo ve patrones anónimos.

07

Clustering por incidente (la jugada central)

El agente busca con embeddings y pgvector si este reporte se parece a otros recientes en la misma zona geográfica. Si encuentra coincidencia, agrupa bajo el incidente existente. Si hay tres o más reportes similares en ventana corta sin incidente abierto, **crea un incidente nuevo automáticamente**. Así es como 200 reclamos individuales se convierten en 1 incidente con 200 afectados.

08

Cumplimiento ASFI automático

El agente genera el número correlativo único exigido por ASFI, inicia el reloj de los 5 días hábiles de respuesta obligatoria, y registra todo en el audit log inmutable con hash encadenado. Cumple por sí solo el Reglamento de Protección al Consumidor Financiero.

09

Generación de respuesta al cliente

El agente selecciona una plantilla aprobada de la base de conocimiento del banco (nunca escribe respuesta libre, lo que elimina riesgo de alucinaciones sobre políticas inexistentes). La plantilla se re-hidrata on-premise con los datos reales del cliente y se traduce al idioma original. Para Doña Justina, la respuesta sale en guaraní.

10

n8n envía la respuesta y notifica al humano

n8n toma la respuesta lista y la envía por la API de WhatsApp Cloud. En paralelo, dispara un segundo workflow que notifica al equipo correcto según el tipo de incidente: técnico de TI para cajero caído, DevOps para app caída, SOC y equipo de fraude para sospecha de fraude. La notificación llega con todo el contexto.

En paralelo: detección emergente de fraude

El mismo motor de clustering que agrupa reclamos operativos vigila patrones anómalos de seguridad en tiempo real. Cuatro patrones disparan alerta automática al SOC:

- **Skimming en cajero o brecha en POS** — 30+ reportes de cargos no reconocidos en una hora en zona geográfica acotada.
- **Phishing o SIM swapping masivo** — picos de «no puedo entrar a la app» combinados con mensajes sobre «SMS raro».
- **Vishing activo** — múltiples clientes mencionan «ejecutivo de BancoSol pidiendo clave».
- **Aplicación falsa circulando** — reportes sobre «app que me bajé no funciona».

BONUS ARQUITECTÓNICO

SolUno detecta horas antes que el equipo tradicional de fraude. No es un módulo aparte: es ciberseguridad emergente de buena arquitectura. El mismo cerebro que agrupa reclamos detecta ataques.

Quién resuelve qué — el reparto exacto

Hay que separar **resolver el reclamo del cliente** (lo hace el agente IA con humano supervisando) de **resolver el incidente operativo de fondo** (lo hace el humano con manos y autoridad). Son cosas distintas.

El AGENTE IA hace solo

- Recibir mensajes de los 9 canales
- Identificar al cliente por contexto
- Tokenizar PII antes de cualquier salida
- Transcribir audio en cualquier idioma
- Clasificar según tipologías ASFI
- Buscar y agrupar incidentes
- Generar número correlativo ASFI
- Redactar respuesta con plantilla aprobada
- Enviar respuesta al cliente
- Detectar patrones de fraude
- Notificar al equipo humano correcto

El HUMANO hace solo

- Aprobar cierre formal de un reclamo
- Aprobar marcado como fraude confirmado
- Decidir bloqueo de tarjetas comprometidas
- Escalar a Defensoría del Consumidor Financiero
- Responder casos complejos derivados
- Arreglar el cajero físicamente
- Desplegar el fix de la app
- Hablar con autoridades policiales
- Cerrar el incidente cuando se resolvió

REGLA QUE ORDENA EL REPARTO

El agente decide lo rutinario y propone lo importante. El humano aprueba lo importante y ejecuta lo físico. Esto se llama **«human in the loop»** y es exigencia regulatoria implícita en cualquier banco que use IA. Sin esto, ninguna propuesta pasa el comité de riesgo.

Por qué n8n es la elección correcta para un banco

n8n es **open source y self-hostable**: se instala dentro del datacenter de BancoSol, no es un servicio cloud externo. Esto elimina de raíz el problema de Tercerización de Servicios Tecnológicos de ASFI — el motor de orquestación vive on-premise.

Cada workflow es un **diagrama visual** que el equipo de TI, Cumplimiento o Auditoría puede abrir, leer y entender sin saber programar. Un auditor de ASFI puede pedir «muéstrenme cómo se procesa un reclamo» y le mostrás una imagen del flujo, no código.

Cada ejecución queda registrada: qué entró, qué salió, cuánto demoró, si falló. **Trazabilidad regulatoria sin esfuerzo adicional.**

El banco puede evolucionar el sistema sin depender del proveedor original. Si BancoSol mañana quiere agregar un canal nuevo o cambiar una regla de escalamiento, su equipo arrastra un nodo en n8n. **Cero vendor lock-in.**

Lo que ven los cinco humanos del banco

Agente de call center / WhatsApp / sucursal

Bandeja 360° del cliente con timeline unificado, banner si el reporte está vinculado a un incidente activo, respuesta sugerida por el agente IA en el idioma del cliente lista para aprobar y enviar.

Supervisor de canal

Cola en tiempo real, SLAs en riesgo en rojo, agentes saturados, botón para re-rutar tickets entre canales y descongestionar.

Operaciones y TI

Mapa de Bolivia con clusters geográficos de incidentes pulsando en tiempo real, lista de incidentes activos ordenados por afectados y severidad, alerta automática cuando se gesta un incidente nuevo. Es la vista que dispara la acción física.

Cumplimiento ASFI

Reportería por tipología, alertas de reclamos próximos a vencer los 5 días hábiles, exporta reportes en formato ASFI con un click.

SOC / Seguridad

La pantalla aparece sola cuando hay señales de fraude, con el cluster de evidencia y la recomendación de acción del agente.

Alineamiento con políticas de privacidad y ASFI

Esta sección demuestra, norma por norma, que SolUno **no infringe ninguna disposición regulatoria boliviana** y se alinea explícitamente con cada exigencia aplicable del sistema financiero. Cada decisión arquitectónica responde a una norma específica.

MARCO LEGAL	OBLIGACIÓN	CÓMO SOLUNO LA RESPETA
ASFI · Reglamento para la Gestión de Seguridad de la Información (RNSF Tít. I, Cap. XXIV)	Comité de seguridad, clasificación de datos sensibles, controles de acceso por rol, gestión de incidentes.	Separación física entre cómputo on-prem (PII en texto plano) y cloud (solo datos tokenizados). RBAC granular: cada rol ve solo lo necesario. Audit log immutable hash-encadenado.
ASFI · Tercerización de Servicios Tecnológicos	Aprobación previa requerida para tercerizar servicios que procesen datos sensibles del cliente.	Ningún dato sensible sale a cloud externo. SolUno no requiere aprobación de tercerización para el LLM cloud porque el LLM solo recibe tokens anónimos. n8n y el LLM on-prem viven dentro del banco.
Reglamento de Protección al Consumidor Financiero	Datos del consumidor no pueden ser cedidos a terceros sin autorización expresa. Número correlativo único. Respuesta en 5 días hábiles.	Tokenización garantiza que ningún proveedor externo recibe datos identificables — no hay cesión . Número ASFI generado automáticamente. Reloj de 5 días monitoreado por el agente con alertas a Cumplimiento.
Constitución Política del Estado, Art. 21 · Privacidad	Derecho del cliente a privacidad, acceso, rectificación y supresión de sus datos personales.	Cada token tiene trazabilidad inversa para responder solicitudes de acceso, rectificación y supresión en menos de 72 horas. Política de retención configurable según el tipo de dato.
ASFI · Reglamento de Riesgo Operativo (Basilea II)	Continuidad del servicio, gestión de eventos de pérdida, plan de contingencia auditado.	Modo híbrido: si cae el LLM cloud, el LLM on-prem mantiene operación completa. Multi-región, RTO 15 min, RPO 1 min. Cada incidente lleva impacto monetario estimado para reportaría al área de Riesgo Operativo.
UIF · Prevención de Lavado y Financiamiento del Terrorismo	Trazabilidad para investigaciones, conservación de evidencia, no obstrucción de monitoreo transaccional.	Cada re-hidratación de token queda registrada con timestamp, usuario y propósito. Reclamos clasificados como «posible fraude» generan flag automático para revisión PLD. Retención de 10 años para casos relacionados a fraude.

MARCO LEGAL	OBLIGACIÓN	CÓMO SOLUNO LA RESPETA
Política interna de BancoSol · Confidencialidad del cliente	Información del cliente no debe ser accesible por personal no autorizado ni terceros no contratados.	Cero PII al cloud por diseño arquitectónico. Empleados con RBAC granular. Detector de acceso anómalo (alerta automática si un empleado abre 200 expedientes en 1 hora — principal vector de fraude interno en LATAM).
Marco de Ciberseguridad (ISO 27001 / NIST CSF)	Defense in depth, gestión de identidad, cifrado en reposo y tránsito, gestión de vulnerabilidades.	AES-256 en reposo, TLS 1.3 en tránsito, OAuth 2.0 + MFA, SSO con AD del banco, DLP filtrando prompts antes de cualquier salida, pentesting anual obligatorio en el roadmap.

FRASE PARA EL JURADO / COMITÉ DE RIESGO

El LLM externo no ve nombres, ni cuentas, ni saldos. Ve patrones anónimos. La identidad del cliente nunca sale del perímetro de BancoSol. Cumplimos ASFI, el Reglamento de Protección al Consumidor Financiero y el Art. 21 de la Constitución — por diseño, no por parche.

10 · SECCIÓN

El principio que ordena todo el sistema

Cero datos confidenciales salen del banco. La arquitectura está dividida físicamente en dos zonas:

ON-PREMISE	Vault de identidad con nombres, CI, cuentas, teléfonos. Tabla de tokens. LLM local (Llama 3.3 / Mistral) para operaciones con PII en texto plano. Whisper local para audios. Audit log inmutable. Motor de re-hidratación. n8n como orquestador.
CLOUD (solo anonimizado)	Clasificación de tipología ASFI, embeddings para clustering, sugerencia de plantilla de respuesta. Todo sobre texto ya tokenizado. Bajo contrato Zero Data Retention con el proveedor.

11 · SECCIÓN

El resultado en una sola frase

SÍNTESIS EJECUTIVA

200 reclamos en 9 canales se convierten en 1 incidente con 200 afectados, detectado en 14 minutos, respondido al cliente en guaraní por el mismo WhatsApp que ya usa, escalado al humano correcto del banco con todo el contexto listo para actuar, y todo sin que un solo dato confidencial salga del perímetro de BancoSol.

El agente IA es el cerebro. n8n es el sistema nervioso. El humano es el músculo y la conciencia ética. El cliente solo siente el resultado.

Documento preparado por **Cristhian Mathias Vargas Menacho** · InnovaHack 2026 · CAINCO · UPSA · Santa Cruz de la Sierra · Bolivia